

# Clasificación de Salmón del Atlantico destinado a filete

Diplomado de Análisis de datos con R para la Acuicultura

Cristian Nagueian Asenjo

30 June 2022

## Tipo de datos

Datos a analizar a partir de un TXT, las que corresponden a las piezas con destino a filete, a continuación se observa que tipo de variables se analizaran y su característica.


```
set.seed(1)
datos <- read.delim("/cloud/project/Piezas a filete.txt", na="NA")
str(datos)
```

```
## 'data.frame':  11526 obs. of  5 variables:
## $ Pieza   : int  1 2 3 4 5 6 7 8 9 10 ...
## $ Peso    : num  3.45 3.78 3.79 3.9 3.69 ...
## $ Largo   : num  0.635 0.635 0.635 0.61 0.635 ...
## $ Calibre: chr   "2.7-4.0" "2.7-4.0" "2.7-4.0" "2.7-4.0" ...
## $ Calidad: chr   "Premium" "Premium" "Premium" "Premium" ...
```

## Describe la variación de las variables de estudio usando histogramas


A continuación se observa dos histogramas para peso y largo, a partir de grafico con 30 barras de distribución, despues tenemos un gráfico de densidad el cual visualiza la distribución de datos cuantitativos para el peso en un intervalo o período de tiempo continuo. Los graficos de distribucion empirica acumulada se puede concluir que presentan una distribucion de tipo normal. (Largo y peso)

```
ggplot(datos, aes(x = Peso)) +geom_histogram(bins = 30, color = "indianred", fill="lightblue")
```




```
ggplot(datos, aes(x = Largo)) +geom_histogram(bins = 30, color = "black", fill="salmon1")
```

```
## Warning: Removed 1165 rows containing non-finite values (stat_bin).
```



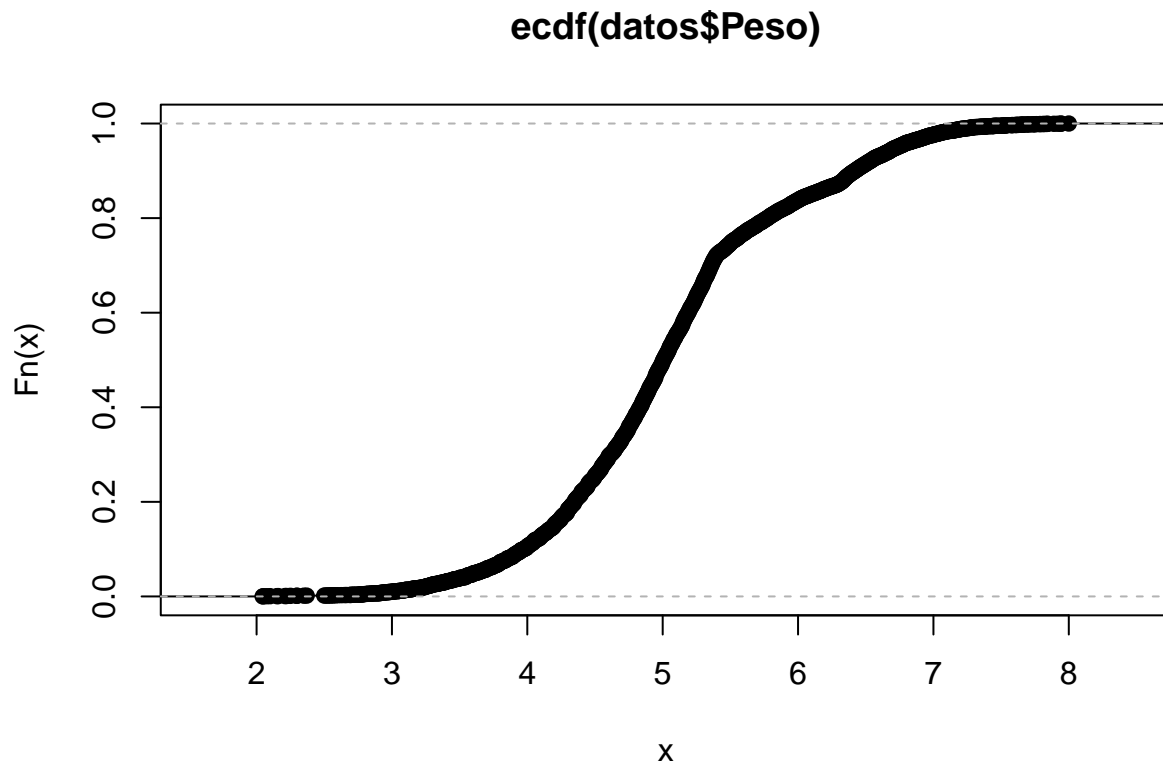
```
plot(density(datos$Peso))
```

**density.default(x = datos\$Peso)**



N = 11526 Bandwidth = 0.1055

```
plot(ecdf(datos$Peso))
```




```
ecdf(datos$Peso) #Distribución empírica acumulada de la variable weight.
```

```
## Empirical CDF
```

```
## Call: ecdf(datos$Peso)
```

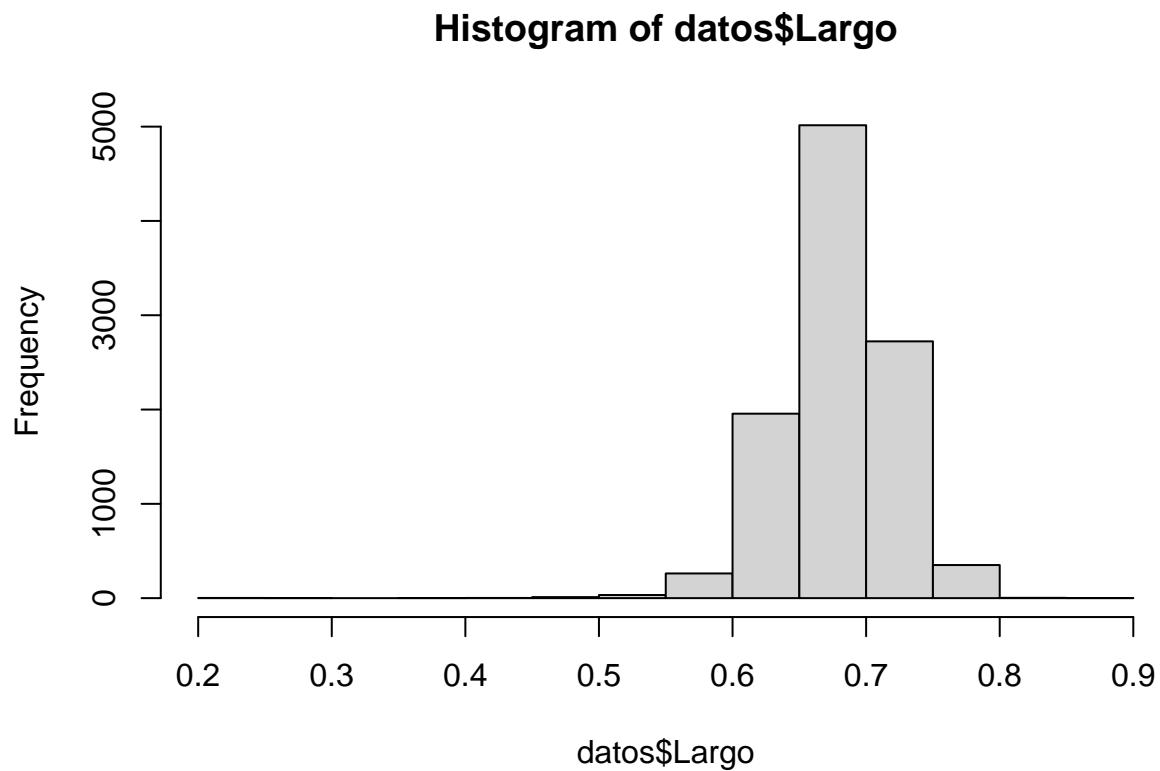
```
## x[1:982] = 2.045, 2.05, 2.075, ..., 7.945, 8
```

```
plot(ecdf(datos$Largo))
```




Identifica si los datos están balanceados o no entre tratamientos usando tablas de frecuencia

```
hist(datos$Largo)
```




```
hist(datos$Peso)
```




**Establece relación entre variables cuantitativas y factores usando gráficas de correlación, boxplot, interacción o de tamaño de los efectos**

Como se puede observar en los siguientes graficos de cajas , entre calidad peso y calibres, peso, los datos obtenidos para este lote no presentan una desviacion significativa. Se puede apreciar que los largos de las piezas para calidad Industrial B, no fueron medidas.

```
ggplot(datos, aes(x=Calidad, y=Peso, fill = Calidad)) +geom_boxplot()+labs(title="Boxplot", x="Calidad"
```




```
ggplot(datos, aes(x=Calibre, y=Peso, fill = Calibre)) +geom_boxplot()+labs(title="Boxplot", x="Calibre")
```



```
ggplot(datos, aes(x=Calidad, y=Largo, fill = Calidad)) +geom_boxplot()+labs(title="Boxplot", x="Calidad")
```


```
## Warning: Removed 1165 rows containing non-finite values (stat_boxplot).
```





```
ggplot(datos, aes(x=Calibre, y=Largo, fill = Calibre)) +geom_boxplot()+labs(title="Boxplot", x="Calibre")
```

```
## Warning: Removed 1165 rows containing non-finite values (stat_boxplot).
```



Identifica si existen errores, datos faltantes o valores atípicos

```
datos$Calibre <- as.factor(datos$Calibre)
datos$Calidad <- as.factor(datos$Calidad)
summary(datos)
```

```
##      Pieza      Peso      Largo      Calibre
## Min.   :    1  Min.   :2.045  Min.   :0.2032  4.5-5.5:5382
## 1st Qu.: 2882  1st Qu.:4.495  1st Qu.:0.6604  4.0-4.5:1637
## Median : 5764  Median :5.010  Median :0.6858  6-7    :1322
## Mean   : 5764  Mean   :5.069  Mean   :0.6769  3-4    : 805
## 3rd Qu.: 8645  3rd Qu.:5.515  3rd Qu.:0.7112  5.5-6.3: 703
## Max.   :11526  Max.   :8.000  Max.   :0.8890  4.2-7.0: 523
##                                     NA's   :1165  (Other):1154
##
##      Calidad
## Industrial B:   71
## Premium      :10898
## Standard     :  557
##
##
##
##
```

Como se puede observar en el resumen de datos, existen 1156 datos de largo los cuales no estan ingresados, debido a que la grader, máquina que calibra las piezas no pudo detectar su longitud.

## Resumen los datos usando tablas y estadística descriptiva

```
table(datos$Calidad)
```

```
##  
## Industrial B      Premium      Standard  
##           71      10898      557
```

```
table(datos$Calibre)
```

```
##  
##      2-3 2.7-4.0 2.7-4.2      3-4 4.0-4.5 4.2-7.0 4.5-5.5      5-6 5.5-6.3 5.6-6.0  
##      81      258      94      805      1637      523      5382      150      703      298  
##      6-7      7-8  
##     1322      273
```

```
mean(datos$Peso)
```

```
## [1] 5.068799
```

```
mean(datos$Largo)
```

```
## [1] NA
```

```
sd(datos$Peso)
```

```
## [1] 0.9123698
```

Se cuantifica un total de 10898 piezas premium, 557 categoria Standard y 71 piezas como industrial B. En tanto para los calibres se observa que 5328 piezas corresponden a calibre 4.5-5.5 Kg. Y por último el peso promedio de este lote fue de 5.068799 Kg.f

## Propone hipótesis y realiza análisis estadístico de los datos, incluye evaluación de supuestos.


### Modelo lineal del análisis de varianza de dos vías con interacción.

```
lm.aov1 <- lm(Peso ~ Calidad, data = datos)  
aov(lm.aov1)
```

```
## Call:  
##      aov(formula = lm.aov1)  
##  
## Terms:  
##              Calidad Residuals  
## Sum of Squares      29.457 9564.169  
## Deg. of Freedom        2    11523  
##  
## Residual standard error: 0.9110471  
## Estimated effects may be unbalanced
```

## Evaluación de supuestos mediante métodos basados en análisis de residuales y pruebas de hipótesis.

```
plot(lm.aov1$residuals, pch=20, col = "blue")
```




Durbin-Watson Test

```
dwtest(Peso ~ Calidad, data = datos,
        alternative = c("two.sided"),
        iterations = 15)
```

```
##
## Durbin-Watson test
##
## data:  Peso ~ Calidad
## DW = 0.17636, p-value < 2.2e-16
## alternative hypothesis: true autocorrelation is not 0
```

Homogeneidad de varianzas


```
plot(lm.aov1, 1, pch=20, col = "blue")
```




```
leveneTest(Peso ~ Calidad, data = datos,
            center = "median")
```

```
## Levene's Test for Homogeneity of Variance (center = "median")
##           Df F value    Pr(>F)
## group      2  15.581 1.748e-07 ***
##      11523
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

plot(lm.aov1, 2, pch=20, col = "blue")
```



```
qqPlot(lm.aov1)
```

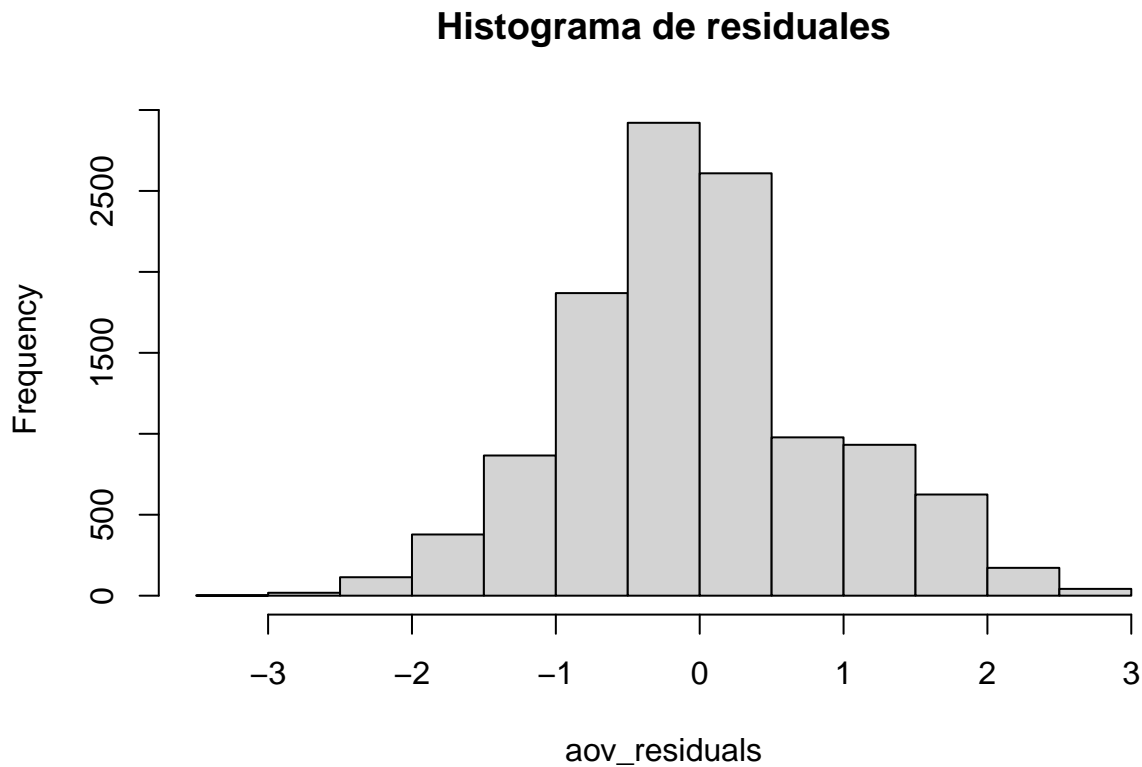


```
## [1] 399 425
```

```
aov_residals <- residuals(object = lm.aov1)
```

## Histograma de residuales

```
aov_residuales <- residuals(object = lm.aov1)
hist(x= aov_residuales, main = "Histograma de residuales")
```



#Se realizaron los gráficos y las pruebas para cada uno de los supuestos. Los resultados de las pruebas mostraron que se cumplían los tres supuestos (independencia, homogeneidad de varianzas y normalidad); ya que éstas pruebas presentaron p-valores superiores al nivel de significación del 5%. Debido al cumplimiento de los tres supuestos, se concluye que para este experimento es posible realizar el análisis de varianza.

**Formule la hipótesis nula y alternativa para evaluar : El peso de salmón es igual para las tres tipos de calidades.**

#H<sub>0</sub>:

$$\mu_{Premium} = \mu_{Standard} = \mu_{IndustrailB}$$

#H<sub>1</sub>: Al menos una de las medias de pesos es diferente para cada calidad.

```
head(datos)
```

```
##   Pieza  Peso  Largo Calibre Calidad
## 1     1 3.450 0.6350 2.7-4.0 Premium
## 2     2 3.780 0.6350 2.7-4.0 Premium
## 3     3 3.785 0.6350 2.7-4.0 Premium
## 4     4 3.905 0.6096 2.7-4.0 Premium
## 5     5 3.690 0.6350 2.7-4.0 Premium
## 6     6 3.615 0.6096 2.7-4.0 Premium
```

```
str(datos)
```

```
## 'data.frame':   11526 obs. of  5 variables:
## $ Pieza   : int  1 2 3 4 5 6 7 8 9 10 ...
```

```
## $ Peso : num 3.45 3.78 3.79 3.9 3.69 ...
## $ Largo : num 0.635 0.635 0.635 0.61 0.635 ...
## $ Calibre: Factor w/ 12 levels "2-3","2.7-4.0",...: 2 2 2 2 2 2 2 2 2 2 ...
## $ Calidad: Factor w/ 3 levels "Industrial B",...: 2 2 2 2 2 2 2 2 2 2 ...
```

```
summary(datos)
```

```
##      Pieza      Peso      Largo      Calibre
## Min.   :    1  Min.   :2.045  Min.   :0.2032  4.5-5.5:5382
## 1st Qu.: 2882  1st Qu.:4.495  1st Qu.:0.6604  4.0-4.5:1637
## Median : 5764  Median :5.010  Median :0.6858  6-7    :1322
## Mean   : 5764  Mean   :5.069  Mean   :0.6769  3-4    : 805
## 3rd Qu.: 8645  3rd Qu.:5.515  3rd Qu.:0.7112  5.5-6.3: 703
## Max.   :11526  Max.   :8.000  Max.   :0.8890  4.2-7.0: 523
##                                     NA's   :1165   (Other):1154
##
##      Calidad
## Industrial B:   71
## Premium      :10898
## Standard     :  557
##
##
##
##
```

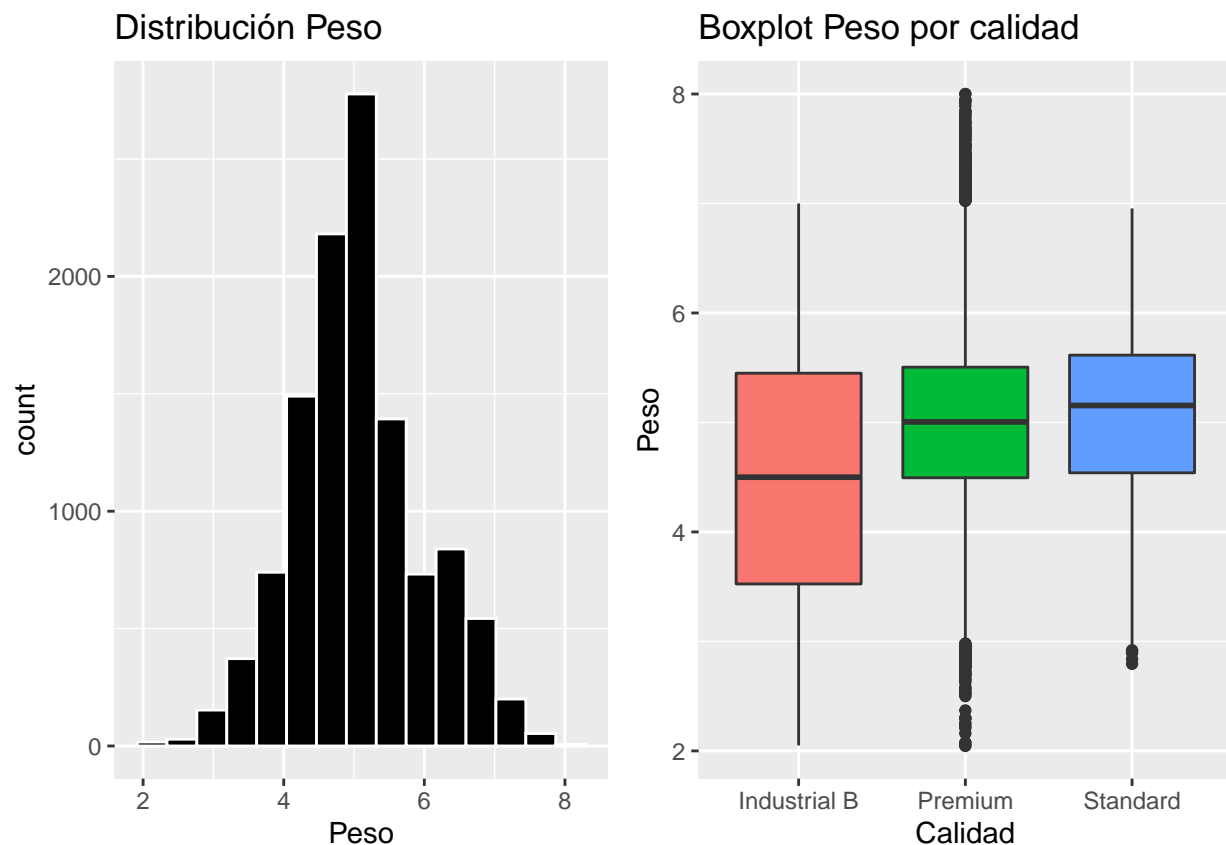
#Análisis exploratorio de datos de la variable bajo estudio Peso, se utilizo geom:histogram() y Geom\_boxplot()

```
plot1 <- datos %>%
  ggplot(aes(x= Peso))+
    geom_histogram(color="white", fill="black", position = "identity", bins = 15)+
    theme(legend.position="none")+
    labs(x="Peso",title="Distribución Peso")

plot2 <- datos %>%
  ggplot(aes(x= Calidad,y=Peso,fill=Calidad))+
    geom_boxplot()+
    theme(legend.position="none")+
    labs(x="Calidad",y="Peso",title="Boxplot Peso por calidad")

grid.arrange(plot1, plot2, ncol=2, nrow =1)
```





#Tabla con los estimadores puntuales de los promedios y las varianzas de la variable Peso para cada calidad.

```
Tabla = datos %>% group_by(Calidad) %>%
  summarize(N= n(), Mean = mean(Peso),
            Variance= var(Peso))
```

```
knitr::kable(Tabla,caption ="Estimadores puntuales de media y varianza de Peso para las Calidaddes, Premium, Standard e Industrial B")
```

Table 1: Estimadores puntuales de media y varianza de Peso para las Calidaddes, Premium, Standard e Industrial B

Calidad	N	Mean	Variance
Industrial B	71	4.428169	1.6776237
Premium	10898	5.071987	0.8334852
Standard	557	5.088070	0.6551205

#Variable respuesta Peso y como factor de clasificación Calidad.

```
model1_anova1 <- lm(Peso ~ Calidad, data=datos)
anova(model1_anova1)
```

```
## Analysis of Variance Table
```

```
##
```

```
## Response: Peso
```

```
##           Df Sum Sq Mean Sq F value    Pr(>F)
```

```
## Calidad      2   29.5   14.728   17.745 2.02e-08 ***
```

```
## Residuals 11523 9564.2    0.830
```

```
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
pander::pander(model1_anova1, caption = "ANOVA a una vía de clasificación.")
```

Table 2: ANOVA a una vía de clasificación. #El efecto Calidad es estadísticamente significativo (p valor menor al nivel de significación del 5%). En consecuencia se rechaza la hipótesis nula. Por lo tanto, existen diferencias entre los pesos promedios de las distintas calidades.

	Estimate	Std. Error	t value	Pr(> t )
<b>(Intercept)</b>	4.428	0.1081	40.96	0
<b>CalidadPremium</b>	0.6438	0.1085	5.935	3.018e-09
<b>CalidadStandard</b>	0.6599	0.1148	5.748	9.261e-09